

Языковая модель — ещё не агент: границы исполнения

Основной план, модуль 01

Краткое содержание

`ModelClient`, `AgentLoop`, `Workflow` и `DistributedExecutor` отвечают на разные вопросы и могут участвовать в обработке одного запроса одновременно. `ModelClient` выполняет один обмен с языковой моделью, `AgentLoop` выбирает следующий шаг, `Workflow` задаёт неизменяемый бизнес-порядок, а `DistributedExecutor` обеспечивает физическое выполнение задачи в одном из исполняющих процессов. Главная граница доверия: ответ модели, включая предложение вызвать инструмент, является данными и предложением действия, но не самим действием.

Ключевые понятия

- **Языковая модель** — вероятно продолжает входную последовательность и возвращает текст либо структурированные блоки. Сама по себе не владеет состоянием и полномочиями приложения.
- **Агент** — программная система, использующая языковую модель для выбора следующего действия в рамках заданных правил, состояния и лимитов.
- **Инструмент** — разрешённая функция приложения с известным контрактом и контролируемыми полномочиями.
- **Вызов инструмента** — структурированное предложение модели вызвать инструмент с аргументами; до проверки и исполнения это недоверенные данные.
- **ModelClient** — адаптер одного обращения к модели: переводит внутренний запрос в протокол поставщика и возвращает нормализованный результат.
- **AgentLoop** — цикл агента: повторяет шаги «обратиться к модели → проверить результат → при необходимости выполнить инструмент → добавить результат в контекст», пока не получен окончательный ответ или не исчерпан лимит. Контекст — факты и сообщения, доступные модели на текущем шаге.
- **Workflow** — заранее заданный процесс: фиксирует допустимые шаги, ветви и бизнес-инварианты до выполнения запроса.
- **DistributedExecutor** — распределённый исполнитель: размещает попытки, отслеживает аренду задачи, отмену и крайний срок, не интерпретируя смысл запроса.


Основные идеи

Проблема: четыре разных вида управления

Фраза «система вызвала модель и при необходимости выполнила инструмент» скрывает четыре независимых решения:

1. **Протокол:** как сериализовать запрос, вызвать конкретного поставщика и без потерь разобрать его ответ? Это граница `ModelClient`.
2. **Семантический следующий шаг:** достаточно ли ответа, нужно ли вызвать инструмент, какой результат добавить в контекст и когда остановиться? Это граница `AgentLoop`.
3. **Бизнес-порядок:** какие этапы обязательны до и после агента, какие ветви допустимы и какой инвариант должен сохраниться? Это граница `Workflow`.
4. **Физическое исполнение:** какой исполняющий процесс и какая попытка выполняются задачу, что делать при потере процесса и как передать отмену? Это граница `DistributedExecutor`.

Эти компоненты не образуют обязательный линейный конвейер. `AgentLoop` и `Workflow` — два способа управлять смысловым переходом: в первом случае следующее действие предлагается моделью во время исполнения, во втором оно заранее закодировано. Их можно скомпоновать, например поместить один ограниченный шаг `AgentLoop` внутри более крупного `Workflow`, но границы ответственности от этого не сливаются. Оба способа могут использовать `ModelClient` и инструменты, а отдельный шаг или весь процесс может размещаться через `DistributedExecutor`.



Две стрелки от запроса показывают альтернативы управления, а не одновременное исполнение. Пунктирные стрелки от `DistributedExecutor` показывают опциональное удалённое размещение уже выбранной работы; они не означают выбор следующего шага. Результаты и ошибки возвращаются по соответствующему пути в обратном направлении, причём каждый слой добавляет только свой контекст и не скрывает исходную причину.

Сравнение границ ответственности

Соответствие строк: 1 — `ModelClient`, 2 — `AgentLoop`, 3 — `Workflow`, 4 — `DistributedExecutor`.

№	Что знает	За что отвечает	Что возвращает наверх
1	Протокол и возможности поставщика	Одно обращение к модели: преобразование данных, отмена, крайний срок, нормализация	<code>UnsupportedCapability</code> , <code>ModelAuthError</code> , <code>ModelRateLimited</code> , <code>ModelTimeout</code> , <code>ModelProtocolError</code>
2	Контекст, разрешённые инструменты, политика и лимит шагов	Проверка предложения, координация исполнения инструмента, обновление контекста, остановка цикла	<code>UnknownTool</code> , <code>InvalidToolArguments</code> , <code>ToolExecutionError</code> , <code>AgentStepLimitExceeded</code> ; <code>ModelError</code> с номером шага
3	Этапы, ветви, бизнес-инварианты, общий крайний срок	Фиксированные переходы, состояние процесса, компенсация	<code>WorkflowInvariantViolation</code> , <code>WorkflowStepFailed</code> , <code>WorkflowDeadlineExceeded</code> , <code>CompensationFailed</code>
4	Задача, очередь, исполняющие процессы, аренды и номера попыток	Доставка, размещение, обнаружение сбоя, статус попытки	<code>TaskDispatchError</code> , <code>WorkerUnavailable</code> , <code>TaskLeaseLost</code> , <code>TaskDeadlineExceeded</code> , <code>AmbiguousCompletion</code>

Слово «наверх» означает непосредственный вызывающий компонент. Например, `ModelTimeout` сначала получает `AgentLoop`, затем `Workflow` может вернуть `WorkflowStepFailed(cause=ModelTimeout)`. `DistributedExecutor` не должен превращать это в безликое `TaskFailed`, иначе теряются решение о повторной попытке, `retry_after`, идентификатор запроса поставщика и диагностическая ценность.

Отказ модели, окончательный текст и предложение вызвать инструмент — варианты нормального ответа модели, а не транспортные ошибки. Аналогично `city not found` является доменным результатом `get_weather`, тогда как падение исполняющего процесса — ошибкой инфраструктуры.

Примеры

Один поток: «Нужен ли сегодня зонт в Казани?»

Чтобы увидеть все четыре границы в одной трассе, предположим, что внешний `Workflow` содержит один ограниченный шаг агента, приложение разрешает только `get_weather(city)`,

а этот шаг запускается на удалённом исполняющем процессе:

1. `Workflow` принимает запрос и достигает заранее заданного шага «получить рекомендацию».
2. `DistributedExecutor` выдаёт попытку этого шага исполняющему процессу. Он видит `task_id`, крайний срок и входные данные, но не решает, нужна ли пользователю погода.
3. `AgentLoop` формирует инструкцию и входные данные для модели и передаёт `ModelClient` текущий контекст вместе со схемой `get_weather`.
4. `ModelClient` выполняет одно обращение. Модель возвращает предложение `tool call: get_weather(city="Казань")`.
5. `ModelClient` только нормализует этот блок. `AgentLoop` проверяет имя, аргументы, полномочия и лимит, затем приложение выполняет инструмент.
6. `AgentLoop` добавляет полученную температуру и осадки в контекст и через `ModelClient` делает второе обращение к модели.
7. Модель возвращает окончательный текст; `AgentLoop` завершает цикл.
8. `DistributedExecutor` фиксирует завершение попытки, а `Workflow` выполняет заранее заданную постобработку и возвращает ответ пользователю.

Если уже первое обращение вернуло окончательный текст, шаги 5–6 отсутствуют. Если погода нужна в каждом запросе без исключений, более простое базовое решение — `Workflow` → `get_weather` → детерминированное форматирование; агент оправдан только тогда, когда адаптивный выбор действительно улучшает измеряемое качество настолько, чтобы окупить задержку, стоимость и новые режимы отказа.

Где возникает ошибка

- Поставщик модели не ответил до крайнего срока: `ModelClient` возвращает `ModelTimeout`; он не объявляет ошибкой всего бизнес-процесса.
- Модель предложила `delete_account`, которого нет в разрешённом наборе: `AgentLoop` возвращает `UnknownTool`; запрос не доходит до исполнителя инструмента.
- Исполняющий процесс умер после побочного эффекта инструмента, но до подтверждения результата: `DistributedExecutor` сообщает `AmbiguousCompletion`. Автоматически повторять весь шаг опасно без `idempotency_key` и сохранённой контрольной точки.
- Финальный ответ нарушил обязательный бизнес-инвариант: `Workflow` возвращает `WorkflowInvariantViolation`, даже если все обращения к модели и инструменту технически успешны.

Практическая проверка границ

Минимальная реализация находится в `lessons/module_01_model_vs_agent`. Она использует `ScriptedTransport` вместо настоящего API и выполняет запрос через четыре границы:

```
Workflow: проверка -> выбор шага
DistributedExecutor: принять -> попытка 1
AgentLoop: модель -> инструмент -> модель -> ответ
DistributedExecutor: подтвердить -> результат
Workflow: проверить результат -> UserResponse
```

Успешная трасса содержит 18 событий: два обращения к `ModelClient`, один проверенный вызов `get_weather` и ни одной повторной попытки. `Trace` хранит упорядоченный журнал в памяти без времени и случайных идентификаторов, поэтому одинаковый сценарий даёт одинаковую последовательность в тестах. Свойство `events` возвращает `tuple`, не позволяя вызывающему коду менять внутренний список.

Практика уточняет владение ошибками. Если абсолютный `deadline` истёк до начала попытки, `DistributedExecutor` создаёт `TaskDeadlineExceeded(task_id=...)`; `Workflow` возвращает вызывающему `WorkflowStepFailed`, сохраняя исходный объект в `cause` и `__cause__`. `AgentLoop`, `ModelClient` и инструмент при этом не запускаются, а событие `attempt_started` отсутствует. Если `deadline` истёк после старта или потеряно подтверждение уже завершённой операции, результатом становится `AmbiguousCompletion`: слепой повтор мог бы продублировать побочный эффект.

`CancelledError` намеренно проходит через все границы без обёртывания. Неожиданные дефекты кода также не маскируются доменными ошибками: `Workflow` оборачивает только ожидаемые `LessonRuntimeError`.

Заметки и наблюдения

Инварианты границ

- `ModelClient` не выполняет инструменты и не поддерживает многошаговую цель.
- `AgentLoop` не знает формат обмена поставщика и не выбирает исполняющий процесс.
- `Workflow` не делегирует модели шаги, порядок которых уже известен заранее.
- `DistributedExecutor` не решает, безопасна ли повторная попытка бизнес-операции. Гарантия «ровно один раз» не возникает из очереди или аренды: неоднозначное завершение требует идемпотентности и проверки фактического результата на границе побочного эффекта.
- Предложение вызвать инструмент не является полномочием. Допуск, проверку схемы и границу арендатора контролирует приложение.

Типичные ошибки проектирования

1. Выполнять предложение инструмента внутри `ModelClient`, смешивая недоверенный ответ поставщика с полномочиями приложения.
2. Называть одно обращение к модели агентом, хотя отсутствуют состояние, выбор шага и цикл.
3. Использовать агента для фиксированного процесса, получая вероятностный и дорогой аналог обычного `Workflow`.

4. Считать `DistributedExecutor` источником смысла бизнес-операции или безопасно повторять всю задачу после любого сбоя исполняющего процесса.
5. Терять исходную ошибку при обёртывании на каждом слое.
6. Смешивать лимит одного обращения к модели, лимит шагов агента, крайний срок `Workflow` и аренду задачи: это разные бюджеты и разные причины завершения.

Ограничения текущей модели

Реализация использует небольшой внутренний контракт и локальный `DistributedExecutor`, а не очередь или гарантию выполнения ровно один раз. В ней нет потоковых событий, частичного ответа, набора разработчика поставщика, полного JSON Schema, согласования возможностей, контрольных точек, воспроизведения и автоматических повторных попыток. Разрешён только инструмент чтения `get_weather`; защита повторного `call_id` не заменяет идемпотентность при новом идентификаторе или перезапуске процесса. Без реального распределения `DistributedExecutor` можно удалить; без адаптивного выбора можно удалить `AgentLoop`.

Вопросы для повторения

1. Модель сразу вернула окончательный текст. Какие компоненты всё равно участвовали, а какой участок `AgentLoop` не выполнялся?
2. Кто должен отклонить предложение вызвать неизвестный инструмент и почему это не `ModelProtocolError`?
3. Исполняющий процесс пропал после записи во внешнюю систему. Почему новая попытка задачи не доказывает, что операция не выполнена дважды?
4. В каком месте сохраняется различие между `ModelTimeout` и `WorkflowDeadlineExceeded`?
5. Какой измеримый результат должен оправдать `AgentLoop`, если `get_weather` вызывается для каждого запроса?

Итоги

Языковая модель генерирует предложение ответа или действия; исполнение и ответственность находятся в коде приложения. `ModelClient` изолирует протокол одного обращения, `AgentLoop` управляет адаптивным многошаговым решением, `Workflow` фиксирует известный порядок, а `DistributedExecutor` переносит вычисление между исполняющими процессами. Чёткие границы позволяют локализовать ошибки и не повторять побочные эффекты из-за сбоя не того слоя. Практика подтвердила эти границы детерминированной трассой и тестами. Следующая тема — независимый от поставщика контракт `ModelClient`, `ModelRequest`, `ModelResponse` и `ModelEvent`.

Источники

- Основной план: модуль 1 и промпт 1.1
- Практика 1.1 и команды запуска
- Правила работы репозитория

Изменчивые API и наборы разработчика не использовались; `verified_at` не требуется. Имена компонентов и ошибок — внутренний учебный словарь.